



Universidad de Los Andes
Facultad de Ingeniería
Departamento de Ingeniería Industrial

PROYECTO DE GRADO
MODELO PARA EL FORECAST DE UNA PLATAFORMA DE FAST DELIVERY EN
COLOMBIA

Autor: María Paula Mejía Tovar
Código: 201415114

Firma: _____

Profesora Asesora: Alejandra Tabares

Bogotá D.C. – Colombia
27 de diciembre – 2023

I. Resumen

En el contexto empresarial actual, las startups han surgido como empresas tecnológicas innovadoras que impactan el mercado. Para mejorar la eficiencia en la entrega, algunas implementan puntos de acopio para la selección y empaque de productos, agilizando las entregas en minutos. La complejidad de las operaciones de entrega rápida requiere un análisis de la variabilidad de la demanda para planificar la capacidad de los centros de acopio y determinar la cantidad de repartidores necesarios, asegurando una gestión logística óptima y una experiencia satisfactoria para los clientes.

El proyecto se aborda en tres secciones, generando modelos de series temporales, desarrollando un algoritmo de optimización para potenciar estos modelos y utilizando dicho algoritmo para configurar los hiperparámetros de los algoritmos de series temporales. Se estudiaron cinco modelos lineales: Exponential Smoothing, ARIMA, VAR, DNN, RNN y LSTM, destacando las series de tiempo, especialmente el algoritmo DNN, por su capacidad para generar los mejores resultados (MSE = 110,047). Se mejoró el algoritmo de optimización, prefiriendo los algoritmos genéticos sobre Grid Search, ya que tienen mayor dispersión (%25th vs %75th: +110%), menor precisión (R^2 : -2.47%) y mayor consumo computacional (segundos de búsqueda mejor solución: +13%). La comparación entre ajustes y penalización exponencial en el algoritmo genético favoreció la penalización exponencial, ya que es el que acelera la convergencia. A pesar del potencial del algoritmo LSTM, su limitado rendimiento (R^2 : -13%) y alto consumo de recursos (segundos por generación: +65%) sugieren que los algoritmos RNN y DNN son opciones eficientes, destacándose el RNN en la predicción de picos de demanda.

Palabras clave: *Fast Delivery, Forecast, Series de tiempo, Algoritmos Genético, Optimización, Grid Search, Exponential Smoothing, ARIMA, SARIMA, DNN, VAR, DNN, RNN, LSTM.*

II. Índice

Contenido

I.	Resumen	2
	Contenido.....	3
	Lista de Ilustraciones.....	5
	Lista de tablas	5
III.	Introducción	6
3.1.	Contexto y Justificación	6
3.2.	Objetivos de la Investigación	6
	General.....	6
	Específicos	7
3.3.	Alcance y Limitaciones	7
3.4.	Estructura de la Tesis	7
	Metodología propuesta	7
	Metodología específica del proyecto	8
IV.	Marco Teórico	9
4.1	Panorama Global.....	9
4.2	Fundamentos de Pronósticos de Demanda	9
4.3	Algoritmos de Pronósticos Tradicionales	10
	Series de Tiempo.....	10
4.4	Algoritmos de optimización para la calibración de hiperparámetros	14
4.5	Algoritmos de optimización y Redes Neuronales	14
	Algoritmo Genético	15
V.	Metodología.....	15
5.1	Recolección y Preparación de Datos	15
5.2	Descripción de Algoritmos Tradicionales Utilizados	16
5.3	Algoritmo de Optimización	17
5.4	Calibración de hiperparámetros con el algoritmo de optimización definido	18
5.5	Evaluación y Comparación de Modelos	20
	MSE.....	21
	R-square.....	21
VI.	Desarrollo y Resultados	23
6.1.	Recursos computacionales.....	23
6.2.	Análisis Exploratorio de Datos	23
	Exploración de la serie de tiempo.	23

Exploración de los modelos predictivos de series de tiempo.....	26
6.3. Resultados de Algoritmos Tradicionales	28
6.4. Resultados de Redes Neuronales	30
Grid Search VS Algoritmo Genético.....	30
Solución a valores indeterminados	32
6.5. Comparación y Análisis de Resultados.....	33
VII. Conclusiones y Recomendaciones.....	38
7.1 Síntesis de Hallazgos Principales	38
7.2 Implicaciones Practicas	39
7.3 Limitaciones del Estudio	39
7.4 Recomendaciones para Futuras Investigaciones.....	40
VIII. Referencias.....	40

Lista de Ilustraciones

ILUSTRACIÓN 1. METODOLOGÍA TOP-DOWN	8
ILUSTRACIÓN 2. EJEMPLO DEL MODELO VAR-NN	12
ILUSTRACIÓN 3. EJEMPLO DE MODELO RNN	13
ILUSTRACIÓN 4. LONG SHORT-TERM MEMORY	14
ILUSTRACIÓN 5. METODOLOGÍA MSE	21
ILUSTRACIÓN 6. EJEMPLO R-SQUARE.....	22
ILUSTRACIÓN 7. SERIE DE TIEMPO ESTUDIADA	23
ILUSTRACIÓN 8. LÍNEA DE TENDENCIA DE LA SERIE DE TIEMPO.....	24
ILUSTRACIÓN 9. DESCOMPOSICIÓN DE LA SERIE DE TIEMPO.	24
ILUSTRACIÓN 10. GRÁFICA DE AUTOCORRELACIÓN.....	25
ILUSTRACIÓN 11. SERIE DE TIEMPO CON LOS OUTLIERS RESALTADOS.	26
ILUSTRACIÓN 12. GRAFICA DE RESULTADOS EXPONENTIAL SMOOTHING	27
ILUSTRACIÓN 13. GRAFICA DE RESULTADOS MODELO ARIMA.....	27
ILUSTRACIÓN 14. GRAFICA DE RESULTADOS MODELO DNN	27
ILUSTRACIÓN 15. GRAFICA DE RESULTADOS MODELO RNN	27
ILUSTRACIÓN 16. GRAFICA DE RESULTADOS MODELO LSTM Y RNN.....	28
ILUSTRACIÓN 17. RESULTADO DE TODOS LOS ALGORITMOS TRADICIONALES	29
ILUSTRACIÓN 18. RESULTADOS DEL EXPERIMENTO ENTRE LOS ALGORITMOS A Y B.....	33
ILUSTRACIÓN 19. GRAFICA DE RESULTADOS CON ALGORITMO GENÉTICO MODELO DNN.....	34
ILUSTRACIÓN 20. GRAFICA DE RESULTADOS CON ALGORITMO GENÉTICO MODELO RNN	34
ILUSTRACIÓN 21. GRAFICA DE RESULTADOS CON ALGORITMO GENÉTICO LSTM	35
ILUSTRACIÓN 22. GRAFICA DE EVOLUCIÓN DEL CON ALGORITMO GENÉTICO PARA EN DNN	35
ILUSTRACIÓN 23. GRAFICA DE EVOLUCIÓN DEL CON ALGORITMO GENÉTICO PARA EN RNN	36
ILUSTRACIÓN 24. GRAFICA DE EVOLUCIÓN DEL CON ALGORITMO GENÉTICO PARA EN RNN ACERCADA.....	36
ILUSTRACIÓN 25. GRAFICA DE EVOLUCIÓN DEL CON ALGORITMO GENÉTICO PARA EN LSTM	36

Lista de tablas

TABLA 1. PARÁMETROS E HIPERPARÁMETROS DE LOS ALGORITMOS SERIES DE TIEMPO.....	17
TABLA 2. ESPACIO DE BÚSQUEDA PARA LOS MODELOS DE SERIES LINEALES.	20
TABLA 3. HIPERPARÁMETROS ALGORITMO GENÉTICO	20
TABLA 4. RESULTADOS DE PRUEBA UTILIZANDO EL ALGORITMO DE CLASIFICACIÓN	21
TABLA 5. RESULTADOS DEL MSE DE LOS ALGORITMOS TRADICIONALES COMPARÁNDOLOS CON LOS DATOS REALES	29
TABLA 6. RESULTADOS EXPERIMENTO CON MODELO DNN USANDO GRIND SEARCH Y ALGORITMO GENÉTICO	31
TABLA 7. RESULTADOS EXPERIMENTO CON MODELO RNN USANDO GRIND SEARCH ALGORITMO GENÉTICO	31
TABLA 8. RESULTADOS DE LAS TRES SERIES DE TIEMPO OPTIMIZADAS.	38

III. Introducción

3.1. Contexto y Justificación

La actualidad ha dado paso al auge de los startups, empresas emergentes que se distinguen por su marcado componente tecnológico y su capacidad para irrumpir en el mercado con ideas innovadoras [1].

Muchos de estos nuevos startups se posicionan como intermediarios entre usuarios, ofreciendo varios servicios, entre los que destaca el comercio electrónico. Actualmente, la demanda de tiempos de entrega cada vez más rápidos impulsa a los negocios a ser más específicos en el volumen de pedidos. En este contexto, varios establecimientos comerciales han adoptado modelos donde la promesa de valor son entregas en menos de 15 minutos, esto hace que su operación se base en puntos de acopio, donde el personal se encarga de la selección y el empaque de los productos elegidos por los clientes [2].

Esta estrategia no solo ahorra tiempo en el servicio de entrega, sino que también posibilita la realización de entregas en cuestión de minutos. Sin embargo, la ejecución de operaciones de entregas rápidas se enfrenta a desafíos complejos, lo que hace que estos negocios deban analizar la variabilidad de la demanda en puntos y horarios específicos.

Esta evaluación minuciosa se traduce en la capacidad de planificar adecuadamente el número de personas en los centros de acopio, así como determinar la cantidad óptima de repartidores a contratar para asegurar una operación eficiente, generar estrategias para atraer esa cantidad de repartidores y así satisfacer las expectativas de los clientes [3].

Dado que estamos ante un problema relativamente novedoso, la disponibilidad de información al respecto es limitada, especialmente en contextos tan específicos como el colombiano. La falta de datos consolidados en este ámbito subraya la importancia de abordar este vacío de conocimiento y entender de manera más profunda cómo los modelos predictivos pueden adaptarse y beneficiar la eficiencia operativa, particularmente en el ámbito de las entregas rápidas.

Es en este contexto que la presente tesis se propone: desarrollar un algoritmo de predicción específico para abordar los desafíos que enfrenta una plataforma de entregas rápidas en el contexto colombiano. Este algoritmo busca llenar el vacío de información existente, del número de órdenes cada media hora y con esto pretende optimizar la programación del personal en cada centro de acopio y los domiciliarios de acuerdo con este número, contribuyendo a una gestión más eficiente y efectiva de los recursos humanos. La implementación exitosa de un algoritmo de predicción lo suficientemente bueno no solo podría mejorar la eficiencia operativa de la plataforma, sino que también podría sentar un precedente valioso para futuras investigaciones y desarrollos en el campo de la logística y la planificación de entregas en la era de la velocidad como oferta de valor.

3.2. Objetivos de la Investigación

General

Desarrollar una herramienta de analítica de datos con el propósito de pronosticar las órdenes en un sistema de Fast Delivery.

Específicos

1. Ajustar diversos modelos de series temporales con el objetivo de pronosticar el número de pedidos.
2. Elaborar un algoritmo de optimización para potenciar el rendimiento de los modelos de series temporales.
3. Configurar los hiperparámetros de distintos modelos de series temporales según la óptima predicción lograda por el algoritmo de optimización desarrollado.

3.3. Alcance y Limitaciones

Este proyecto de grado propone la implementación de un Forecast que no solo optimice la eficiencia operativa del negocio de Fast Delivery, sino que también le permita anticipar y adaptarse a las fluctuaciones de la demanda cada 30 minutos, garantizando así una satisfacción óptima de las necesidades de los clientes [4]. Se busca minimizar la subutilización de recursos y evitar el exceso de inventario, factores esenciales para la rentabilidad y competitividad en el mercado actual. Entonces necesitamos crear un pronóstico que pueda prever cada media hora durante un mes y que no tome más de 56 horas para calibrar el modelo de serie de tiempo, para ser oportunos con la operación.

Es crucial reconocer las limitaciones inherentes al problema, ya que el comportamiento del Forecast puede verse afectado por picos inesperados en la demanda, y la capacidad de adaptación del modelo a variaciones estacionales y al crecimiento continuo del negocio de Fast Delivery es fundamental. Estas consideraciones son cruciales para desarrollar un sistema de previsión robusto que no solo cumpla con las expectativas mencionadas, sino que también pueda evolucionar y adaptarse a medida que el entorno comercial cambie.

En este sentido, el proyecto se centra en una solución general que desarrolla un modelo basado en toda la información disponible, sin segmentar las órdenes por zona o centro de acopio, y sin contar con información complementaria que podría agregar al modelo, como fechas especiales.

3.4. Estructura de la Tesis

Metodología propuesta

La estrategia operacional se forma a partir de procesos complejos divididos en múltiples niveles organizacionales. En un proyecto de ingeniería, establecer una estrategia operacional es de vital importancia para lograr una comprensión profunda del alcance del proyecto y a su vez, dividirlo en segmentos que puedan realizarse con mayor facilidad. Uno de los métodos con mayor aceptación en el campo de la gestión de proyectos es el top-down, el cual se basa en la idea de ‘formulación y ejecución’.

En concreto, la estrategia de top-down puede describirse como la coordinación planeada de intenciones y acciones para conseguir resultados específicos impuestos por una autoridad central. Este enfoque especifica las metas a largo plazo, intenciones y tácticas de forma previa a la ejecución del proyecto. Se crea un plan de trabajo detallado con el fin de dejar el menor número de factores por definir a la hora de llevar a cabo las acciones propuestas. En la estructuración de proyectos, se utiliza un diagrama de flujo que divide las tareas de orden mayor en otras de orden específico. El proyecto está conformado por diferentes niveles, que a medida que aumentan, se incrementa la profundidad del detalle, como se muestra en la siguiente imagen.




Ilustración 1. Metodología top-down.

Para estructurar la estrategia de acuerdo con el modelo de *top-down* se utiliza una herramienta llamada *work breakdown structure* o WBS. El WBS lista las tareas que deben realizarse en la forma de resultados entregables, en lugar de acciones. Esto es preferible debido a que al inicio del proyecto es más fácil conocer los resultados que se desean obtener que las acciones que conducirán a ellos [5]. Las ventajas de trabajar con un WBS son:

- Permite una aproximación más definida y puntual al proyecto.
- El trabajo se simplifica y resulta en acciones de alcance directo.
- Indica las fases del proyecto y establece varios puntos de verificación del avance.
- Es un indicador para estimar la duración y alcance del proyecto.
- Funciona como una herramienta en la toma de decisiones.

Garantiza que no se incluyan tareas innecesarias en la ejecución del proyecto [6].

El WBS se compone de tres niveles. El primer nivel está conformado por el objetivo global del proyecto. El segundo nivel consiste en la etapa de estructuración, mientras que el tercero se enfoca en los resultados esperados de cada una de las etapas. Es posible añadir uno o más niveles de acuerdo con la complejidad del proyecto.

Metodología específica del proyecto

Con base en la metodología seleccionada, se opta por dividir el problema en tres capítulos estratégicos. En primer lugar, se aborda la creación de modelos de series temporales, centrándose en el diseño y desarrollo de herramientas que capturen de manera efectiva el comportamiento de los datos a lo largo del tiempo. En el segundo capítulo, se concentra en la creación de un algoritmo de optimización diseñado específicamente para mejorar los modelos previamente creados. Este algoritmo busca perfeccionar la precisión y la capacidad predictiva de los modelos de series temporales. Finalmente, el tercer capítulo se dedica a la implementación del algoritmo de optimización en aquellas series de tiempo que presenten la necesidad de una mejora.

El desglose de estos capítulos condujo a la organización de seis secciones detalladas. La primera sección se enfoca en la generación de conocimientos fundamentales sobre las series temporales, estableciendo una base sólida para comprender los conceptos y principios clave. La segunda sección aborda la recolección y preparación de los datos de estudio, destacando la importancia de obtener información de calidad y adecuadamente

estructurada. La tercera sección se dedica al estudio de algoritmos tradicionales que se utilizarán como referencia en el desarrollo de modelos de series temporales. La cuarta sección explora los posibles algoritmos de optimización que pueden aplicarse al problema en cuestión. La quinta sección se centra en la calibración de hiperparámetros utilizando el algoritmo de optimización definido en el segundo capítulo, buscando afinar los modelos de series temporales. Finalmente, la sexta sección implica la evaluación y comparación exhaustiva de los modelos, analizando su rendimiento en función de métricas específicas para determinar la efectividad de las mejoras implementadas.

IV. Marco Teórico

4.1 Panorama Global

En el mundo, son pocas las empresas que han logrado tener una operación de entregas rápidas. Entre las más conocidas se encuentran Postmates, Doordash y Gorillas, siendo este último el único que ofrece entregas en menos de 10 minutos. Gorillas es básicamente la única empresa en Europa en crear este sistema y está avalada en un billón de dólares. Su modelo de negocio le ofrece al cliente más de 2000 artículos que se entregan en menos de 10 minutos [7].

El modelo de negocio de Gorillas, aunque muy nuevo, se ha expandido a 20 ciudades a lo largo de Europa, donde otras empresas de delivery alrededor del mundo han querido seguir sus pasos, como Getir en Turquía o Rappi en Latinoamérica. La expansión de este modelo de negocio se debe principalmente al afán de estas empresas de crear un servicio que permite al usuario tener un supermercado a la mano, lo que ha generado que el negocio no solo se expanda alrededor del mundo, sino que también se expanda en el tipo de servicios que ofrece [8]. Debido a lo novedoso que logra ser este modelo de negocio y a lo complejo de su operación, actualmente es muy poca la información que se tiene al respecto de modelos que logren generar predicciones de lapsos de tiempo tan pequeños.

4.2 Fundamentos de Pronósticos de Demanda

El proceso de Forecasting, o pronóstico, desempeña un papel fundamental en la gestión logística al permitir a las empresas anticipar y prepararse para la demanda futura de sus productos o servicios. Esta anticipación es esencial para la toma de decisiones informadas en diversas áreas, como la producción, el inventario y la asignación de recursos.

Según las perspectivas del Dr. Chaman L. Jain, autor del libro "Fundamentals of Demand Planning and Forecasting", la mejora en la precisión del pronóstico de la demanda requiere una combinación hábil de modelos estadísticos, análisis de datos y experiencia práctica en el campo. En este contexto, el primer paso crucial implica la recopilación y análisis exhaustivo de datos, aprovechando información histórica de ventas, tendencias de mercado y otros datos relevantes para identificar patrones significativos [9].

Una vez que los datos están debidamente preparados, se emplean modelos estadísticos que incluyen análisis de series temporales, análisis de regresión y técnicas de aprendizaje automático. Cuando los datos están preparados, se emplean modelos estadísticos con análisis de series temporales, análisis de regresión y técnicas de aprendizaje automático. Estos modelos permiten identificar patrones y tendencias en los datos, posibilitando la generación de predicciones más precisas sobre la demanda futura. Este enfoque no solo

se basa en la observación de eventos pasados, sino que también se apoya en la capacidad de adaptación de los modelos a condiciones cambiantes del mercado.

La validación de los resultados es una etapa crítica del proceso, involucrando la revisión y corroboración de los pronósticos con las partes interesadas. Las decisiones estratégicas sobre la asignación de recursos se toman a partir de estos resultados validados. Es importante destacar que el proceso de Forecasting no concluye una vez que se establecen los modelos; por el contrario, es un proceso continuo. El monitoreo constante del rendimiento del modelo es esencial, permitiendo ajustes periódicos basados en nuevos datos y en las dinámicas cambiantes del mercado.

En resumen, el Forecasting no solo se trata de prever la demanda, sino de un proceso integral que fusiona análisis estadísticos, experiencia práctica y adaptabilidad continua para proporcionar pronósticos precisos que respalden decisiones logísticas fundamentales.

4.3 Algoritmos de Pronósticos Tradicionales

Series de Tiempo

Debido a la amplia cantidad de restricciones que se puede tener en un servicio de envíos rápidos, existen múltiples modelos que lograrían predecir la demanda en los puntos de acopio, por lo que deberá ser necesario revisar cada uno de ellos para ver cual se adapta mejor [10].

Ahora, para el problema actual existen modelos de series de tiempo las cuales extraen información sobre el comportamiento anterior del Forecast y con esto el modelo toma una decisión basada en la información disponible. Ahora bien, todo debe iniciar por la definición de algunas estadísticas básicas que representan las propiedades de una serie antes de usar cualquier método de pronóstico. Este razonamiento se basa en el concepto de tiempo estocástico del proceso en serie, que se define de la siguiente forma: Se considera un set de observaciones de una variable X , donde X pertenece a S . El set X es un proceso estocástico $\{X_t\}$, donde t es el tiempo específico donde se realizaron las observaciones, por lo que t pertenece al espacio tiempo descrito por la función de densidad de probabilidad. Esta función tiene la forma $f(X; \theta|S, \omega)$ donde ω es la probabilidad del espacio $f(X; \theta)$ y θ es el vector de los parámetros que describen su comportamiento [11].

Exponential Smoothing

Una de las series de tiempo más antiguas y estudiadas el Exponential Smoothing, inicia su estudio en los años 50's, debido que su estimador de parámetros es bastante intuitivo y fácil de entender. Por esta razón es uno de los métodos más implementados en la industria, los valores de la serie temporal siguen una tendencia gradual, y al mismo tiempo tienen un comportamiento estacional en el que los valores siguen un patrón cíclico repetido durante un número determinado de pasos de tiempo [12].

Este modelo es similar al Holt's Winter Method, ya que la predicción es una suma ponderada de observaciones pasadas, pero el modelo utiliza un decrecimiento exponencial decreciente para las observaciones del pasado, sobretodo si se ponderan en una relación geométrica decreciente [13]. La desventaja de este tipo de modelo es que no suele ser muy bueno en el largo plazo, por lo que normalmente se utiliza para predecir sucesos recientes y no suele ser un modelo que pueda seguir tendencias, como si lo puede hacer un modelo ARIMA o SARIMA [14].

ARIMA

Ahora, entre los modelos más importantes en series de tiempo son los ARIMA, son muy populares porque al usar datos de forma temporal comprende mejor los datos y así predecir tendencias futuras. Este modelo necesita de valores pasados para lograr realizar sus predicciones, lo que significa que logra pronosticar el comportamiento de ventas del Forecast en función de periodos anteriores [15].

Del teorema the Wold Decomposition se sabe que cualquier proceso estacionario indeterminista puede escribirse como una media móvil infinita. Dicho proceso se puede aproximar, con cualquier nivel de precisión, mediante un modelo dentro de la clase ARMA. En principio, debería encontrarse un modelo ARMA parsimonioso en el sentido de que p y q son relativamente pequeños. Si bien la mayoría de las series de tiempo no son estacionarias, pueden volverse estacionarias mediante operaciones como la diferenciación. Este argumento se encuentra respaldado por la observación de pronósticos obtenidos de modelos contruidos de la manera descrita, y que corresponden a procedimientos del Holt's method [15].

El modelo Arima es un método utilizado principalmente para pronosticar o predecir resultados futuros basados en una serie de tiempo histórica [16]. Este método usa el concepto estadístico de correlación serial, donde los puntos de datos pasados influyen en los puntos de datos futuros, para realizar predicciones certeras en tiempos cortos [17].

En comparación con otros modelos, este tiene la ventaja de ser bueno con predicciones a corto plazo, no es necesario ingresar data adicional a la historia y es un modelo no estacional [18]. Lastimosamente no es muy bueno con predicciones a largo plazo, es malo prediciendo picos de demanda, es computacionalmente costo y sus parámetros de entrada pueden ser subjetivos.

VAR

El modelo Vector Autoregressive se define como un algoritmo de pronóstico multivariado que es utilizado cuando dos o más series de tiempo se influyen entre sí [19]. A diferencia de los algoritmos de pronóstico univariados (AR, ARMA, ARIMA), donde se predice una variable dependiente del tiempo, aquí se tienen una o más variables que dependen del mismo.

Normalmente se utiliza este algoritmo cuando existen efectos causales de las variables endógenas entre sí, algún tipo de impacto dinámico entre los cambios de una variable sobre otras en el modelo y la existencia de varianza en cada variable que puede atribuirse a cambios [20]. Ahora, existen variaciones de este modelo, donde se aplican redes neuronales a los datos multivariados, para así generar pronósticos con series de tiempo. El modelo Vector Autoregressive Neural Network (VAR-NN) se genera a partir de un vector de un modelo autorregresivo y representa un modelo no lineal y no paramétrico [21]. La arquitectura de VAR-NN se construye de manera similar a la de un modelo Auto Regresivo con Redes Neuronales, estos usan la capa de salida que contiene más de una variable (multivariante), mientras que la entrada contiene las variables de las observaciones de retrasos anteriores de cada variable de salida. Lo anterior se logra explicar en la ilustración 2.




Ilustración 2. Ejemplo del modelo VAR-NN

DNN

El modelo DNN (Deep Neural Network) es un tipo de red neuronal de múltiples capas, lo que significa que aprende mediante representaciones jerárquicas de los datos de entrada a través de diferentes capas y nodos ocultos, ajustando los parámetros en su interior para así minimizar la diferencia entre los en input y el output. El proceso de entrenamiento implica ir entre los valores del pasado y el futuro, para que de esta forma exista un óptimo peso entre los datos utilizando la propagación y un algoritmo de optimización [22].

La forma en la que el modelo funciona es a través de una capa de inicio, unas capas ocultas y una capa de salida. La capa de entrada es la que se encarga de recibir la información y configurarla de tal forma que quede un data set, cada nodo o neurona representa un parámetro para la predicción. Entre la capa de entrada y salida se esconden más capas, donde cada nodo de estas capas ocultas aplica un peso y una penalización, estas pasan el resultado a través de una función de activación, por lo que estas se encargan de ayudar a que el modelo aprenda de forma compleja la data de entrada. Ahora, la capa de salida se encarga de crear la predicción, por lo que el número de nodos de la capa de salida depende de la tarea, ya sea clasificación binaria o multiclase.

RNN

RNN (Recurrent Neural Networks) es un tipo de Red Neuronal que pertenece a los algoritmos más utilizados debido a la memoria de este. Por esta razón es un algoritmo potente y robusto. Este algoritmo puede recordar cosas sobre la información de entrada, lo que significa más precisión con sus predicciones, por esta razón es uno de los algoritmos más utilizados en series de tiempo, ya que puede llegar a crear un entendimiento profundo de una secuencia y compararla [23].





Ilustración 3. Ejemplo de modelo RNN

Este tipo de algoritmo es increíblemente bueno para series que contengan un conjunto de datos que sigan patrones estacionales homogéneos, y que cubran la misma duración de tiempo, ya que este algoritmo logra capturar la estacionalidad sin una desestacionalización previa [24], lo anterior se logra observar en la ilustración 3. Eso sí, estos algoritmos no son muy buenos al intentar modelar la estacionalidad sin guía previa, por lo que se debe ajustar y remover las series originales los efectos de la estacionalidad.

La principal diferencia entre el modelo DNN es que son efectivas para predicciones con patrones fijos, mientras que el modelo RNN identifica el orden y el contexto de la secuencia de entrada. Ya que el modelo RNN logra tener conexiones recurrentes que forman ciclos para manejar dependencias secuenciales [25].

Long Short-Term Memory (LSTM)

El algoritmo LSTM (Long Short-Term Memory) puede confundirse con el algoritmo RNN, pero mientras el segundo únicamente combina los estados previos con la nueva proyección y los pasa por la función de activación, el primero utiliza varias entradas para decidir qué información toma o descarta. Es por esta razón que este algoritmo llega a ser más complejo, y por lo tanto consume más gasto computacional [26].



Este algoritmo está diseñado para evitar el problema de dependencia a largo plazo, ya que recuerda la información durante largos periodos, y por eso no le cuenta aprender nuevas tendencias, lo anterior se logra observar en la ilustración 4. Aunque su estructura logra ser parecida a la del algoritmo RNN, tiene cuatro redes neuronales y no solo una [23].

4.4 Algoritmos de optimización para la calibración de hiperparámetros

La calibración de hiperparámetros en modelos de series temporales constituye un paso fundamental en el proceso de modelado, ya que es en esta fase donde se perfecciona la configuración del modelo para optimizar su precisión y sus capacidades predictivas. El propósito principal de este proceso radica en ajustar los hiperparámetros del modelo de manera que las predicciones se alineen de manera más precisa con los datos históricos, generando así proyecciones más acertadas [27].

Como punto de partida, se eligen ciertos valores para los hiperparámetros del modelo, a menudo basados en configuraciones predeterminadas proporcionadas por el marco del modelo. Posteriormente, estos hiperparámetros se ajustan de manera sistemática mediante técnicas de optimización, tales como grid search, random search, o incluso enfoques más avanzados como algoritmos genéticos u optimización bayesiana [28].

Es común emplear técnicas de cross-validation para validar el rendimiento del modelo en distintos subconjuntos de datos, asegurando así que su eficacia no dependa de un conjunto específico de observaciones. La efectividad de estos algoritmos de optimización se vincula estrechamente con la cantidad de hiperparámetros en el modelo de series temporales, y en este punto es crucial decidir si utilizar métodos convencionales o recurrir a enfoques más avanzados, como los algoritmos genéticos [29].

El proceso de optimización desencadena una serie de iteraciones donde se recalibra el modelo de series temporales en cada paso. Tras ajustar los hiperparámetros, se vuelve a entrenar el modelo, se evalúa su rendimiento y se repite el proceso durante las iteraciones necesarias para obtener una respuesta precisa.

Previamente a la fase de iteración, es esencial incorporar técnicas de regularización para evitar el sobreajuste a los datos. La regularización contribuye a controlar la complejidad del modelo y garantiza que este se generalice eficientemente a nuevos datos, salvaguardando la calidad de las predicciones [27].

Este proceso resulta esencial en la construcción de modelos de series temporales, ya que demanda calibraciones continuas con la consideración de nuevos datos. Este enfoque iterativo contribuye a la mejora constante del Forecast, permitiendo la toma de decisiones más informada y eficaz a lo largo del tiempo.

4.5 Algoritmos de optimización y Redes Neuronales

Los algoritmos de optimización son procesos matemáticos cuyo fin es encontrar la mejor solución, ya sea mínima o máxima, para un problema determinado. Estos algoritmos son utilizados normalmente para temas como el machine learning, la investigación de operaciones, la ingeniería, la economía, etc. Estos algoritmos son esenciales cuando el problema de estudio puede tener un número de respuestas elevado y se busca encontrar iterativamente hasta alcanzar una solución óptima o casi óptima.

Es por la cantidad de enfoques que estos algoritmos tienen, que la efectividad de estos dependerá de las características del problema, el tipo de función objetivo, los recursos computacionales disponibles y otras consideraciones. Por todo lo anterior, para el problema descrito en este documento, el algoritmo genético es el más idóneo, ya que este itera de forma evolutiva, tal y como se hace en el proceso de selección natural, por lo que las soluciones pasan por un proceso de múltiples generaciones, donde en cada una se está más cerca de converger en la mejor solución [30].

Algoritmo Genético

Como se mencionaba anteriormente los algoritmos genéticos son algoritmos de optimización inspirados en los principios de la selección natural y la genética. Por lo que imitan el proceso de evolución para buscar y refinar de forma iterativa soluciones a problemas de optimización. Su funcionamiento se explica de la siguiente forma: el algoritmo inicia con una población inicial de soluciones potenciales, a lo que se le llama población.

Cada posible solución o individuo tiene un conjunto de hiperparámetros que forman una solución potencial al problema de optimización en cuestión [31]. Este proceso se desarrolla a lo largo de una serie de generaciones, donde los individuos evolucionan y compiten por la supervivencia.

El método de evolución se realiza por medio de operadores genéticos, que son la selección, el cruce y la mutación. La selección es el proceso en el que se escoge que individuos son idóneos para pasar sus hiperparámetros(genes) a la siguiente generación, para esto se usa una función objetivo asociada a cada individuo [31]. Una vez se tienen los padres, inicia la etapa de cruce, lo que implica combinar el material genético de dos padres para crear uno o más descendientes, este proceso genera diversidad y crea nuevas soluciones potenciales mediante el intercambio de información entre individuos.

Ahora, la mutación es un proceso que ayuda a explorar más posibles soluciones y previene converger en subóptimas condiciones, esto se hace al cambiar de forma aleatoria algún parámetro de una solución “hija”. El proceso anterior se repite una y otra vez, generando mejores poblaciones, y por lo tanto convergiendo hacia mejores soluciones, todo esto hasta cumplir con un criterio de parada, que puede ser un número predefinido de generaciones o alcanzar un nivel satisfactorio de calidad de la solución [31].

V. Metodología

5.1 Recolección y Preparación de Datos

Para la recolección de datos, se contó con la colaboración de una empresa dedicada al servicio de Fast Delivery. Esta empresa facilitó información sobre las órdenes realizadas a través de su aplicación, incluyendo las fechas en las que se llevaron a cabo. Siguiendo las directrices de confidencialidad solicitadas por la empresa, se procedió a realizar una modificación en los datos originales.

El éxito del experimento está directamente vinculado a la efectividad de la partición de los datos, ya que el algoritmo de la serie de tiempo requiere una lectura precisa de la granularidad del tiempo. La granularidad, en este contexto, se refiere a los intervalos o frecuencia con los que se registran las observaciones, en nuestro caso, el número de órdenes [32].

Es fundamental comprender que la elección de la granularidad temporal influye significativamente en la capacidad del algoritmo para extraer conocimientos y patrones de los datos. Por ejemplo, al analizar la tendencia, intervalos de tiempo más pequeños pueden revelar patrones intrincados, mientras que intervalos más amplios podrían pasar por alto estas sutilezas [33].

La granularidad es crucial para identificar la estacionalidad de los datos, algo relevante para este proyecto de grado. Los patrones recurrentes en intervalos de tiempo específicos, como diarios, semanales o anuales, pueden afectar significativamente los resultados del análisis [33].

La elección adecuada de la granularidad impacta el tiempo de respuesta y la latencia del modelo, ya que la generación de pronósticos puede variar según la cantidad de detalles necesarios. Una granularidad detallada permite respuestas más rápidas a cambios, mientras que una granularidad más amplia puede conducir a conocimientos menos precisos [34].

Es esencial considerar que el uso de una serie temporal detallada conlleva mayores requisitos de almacenamiento y procesamiento de recursos. Esto plantea un desafío de equilibrio entre el nivel de detalle necesario y los recursos disponibles, afectando tanto la eficiencia del modelo como la velocidad de recuperación de datos [33].

En el contexto específico de este proyecto de grado, se determina que la granularidad necesaria debe permitir la generación de pronósticos cada media hora para el número de órdenes en una empresa de Fast Delivery. La elección adecuada de la granularidad temporal se vuelve, por lo tanto, vital para garantizar que el proyecto esté alineado con los objetivos del análisis y los requisitos de la aplicación.

Con base en estas consideraciones, se procedió a procesar los datos para organizarse en formato compatible con los algoritmos de series temporales. Se estableció una estructura donde la primera columna registra la secuencia de tiempo, asignando intervalos solo por día y, después, incluyendo secuencias de día, hora y minutos, particionadas entre 0 y 30 minutos. La segunda columna cuenta el número de órdenes en cada intervalo de tiempo establecido en la primera columna.

5.2 Descripción de Algoritmos Tradicionales Utilizados

En el marco de este proyecto de grado, se abordarán los algoritmos de series temporales explorados en el contexto teórico del documento. En lugar de emprender la tarea de desarrollar estos algoritmos desde cero, se optará por la utilización de las librerías en Python de tensor Flow que facilitarán su implementación. Este enfoque se alinea con el objetivo principal del proyecto, que se centra en ajustar diversos modelos de series temporales para anticipar el número de pedidos en una empresa de Fast Delivery, en lugar de la creación de un nuevo modelo de series temporales.

Es relevante destacar que, si bien no se ha concebido la creación de nuevos algoritmos, se ha llevado a cabo un ajuste en los hiperparámetros de cada uno de ellos. La elección de estos hiperparámetros se realizó sin seguir una lógica específica, ya que se espera perfeccionarlos en las fases subsiguientes del proyecto. En este sentido, se ha dado un paso inicial ajustando los hiperparámetros con el propósito de realizar un primer diagnóstico de los modelos empleados. Estos hiperparámetros seleccionados, aunque no han seguido

un criterio particular, constituyen un punto de partida para la optimización y refinamiento posterior de los algoritmos. Aun así, se realiza una evaluación preliminar de la capacidad predictiva de los modelos y se sienta las bases para iteraciones posteriores con ajustes más fundamentados con los siguientes hiperparámetros:

Model	Parameter	Value
ARIMA	resample_frecuency	D,W
VAR	covars	num_stores
DNN	EPOCHS	25
	BATCHSIZE	[16,32]
	Hidden Layer Size	[64,128]
	Embedding Layer Size	[32,64]
RNN	Activation	tanh
	Optimazer	adam
	ClipValue	5,00
	Learning Rate	0,01
	EPOCHS	5
	LSTM_units	[64^2]
LSTM	Activation	tanh
	Optimazer	adam
	ClipValue	5,00
	Learning Rate	0,01
	EPOCHS	5
	RNN_units	[64^2]

Tabla 1. Parámetros e hiperparámetros de los algoritmos series de tiempo.

5.3 Algoritmo de Optimización

Para descubrir la mejor combinación de hiperparámetros para las diversas series de tiempo, es esencial emplear un algoritmo de optimización que explore exhaustivamente las posibles respuestas que los modelos pueden generar con diferentes configuraciones de hiperparámetros.

En una primera fase, se opta por utilizar el método del Grid Search como algoritmo de optimización. Este enfoque explora sistemáticamente todas las soluciones potenciales que pueden ser generadas por los distintos hiperparámetros en la serie de tiempo seleccionada. Sin embargo, para evaluar su eficacia, se compara con la opción más comúnmente utilizada en modelos de series temporales: los algoritmos genéticos. Estos últimos se destacan por su capacidad para seleccionar eficientemente respuestas prometedoras sin recorrer exhaustivamente cada respuesta individual. Este análisis se lleva a cabo con el propósito de determinar si vale la pena implementar un algoritmo genético, considerando la posibilidad de recorrer cada respuesta con el Grid Search. En este contexto, se realiza un experimento específico para las dos series de tiempo que presentan un mayor número de hiperparámetros, con el objetivo de obtener conclusiones claras sobre la efectividad de cada enfoque.

Si la opción del algoritmo genético demuestra ser más favorable, hay que considerar cómo seleccionar los "padres" para las generaciones siguientes. Algunas combinaciones de

hiperparámetros pueden generar resultados indefinidos, y si se reproducen en el algoritmo genético, podrían impedir la obtención de la mejor respuesta posible. Por eso, se diseña un experimento adicional para comparar diversas metodologías para la selección de padres. Este análisis busca identificar el mejor enfoque que garantice la reproducción eficiente de combinaciones de hiperparámetros prometedoras y evite posibles resultados indefinidos que podrían afectar negativamente el rendimiento del algoritmo genético.

5.4 Calibración de hiperparámetros con el algoritmo de optimización definido

En esta fase crucial del proyecto de grado, se implementa el algoritmo de optimización previamente seleccionado para ajustar y optimizar los hiperparámetros de los modelos de series temporales bajo estudio. Este proceso se erige como el eslabón esencial que vincula la calidad de las predicciones con la capacidad de los modelos para adaptarse a la realidad cambiante de los datos temporales. Podríamos afirmar con certeza que la calidad del Forecast resultante está intrínsecamente ligada al trabajo preliminar realizado, que comprende la minuciosa evaluación de los modelos de series temporales utilizados para la generación de pronósticos.

El cimiento de esta etapa descansa en la información acumulada a partir de los diversos modelos de series temporales, cada uno caracterizado por sus propios parámetros y configuraciones. Este conjunto de conocimientos actúa como el punto de partida esencial para la labor del algoritmo genético, que desempeñará un papel crucial en la optimización de las predicciones. La sinergia entre la información previa y la capacidad del algoritmo genético para refinar y ajustar los parámetros resulta determinante en la obtención de un Forecast de calidad superior.

Es crucial destacar que, al gestionar la optimización de los hiperparámetros, no solo se está perfeccionando la capacidad predictiva de los modelos de series temporales, sino también se está fortaleciendo la capacidad de adaptación y generalización a patrones cambiantes en los datos. Esta adaptabilidad adicional contribuye significativamente a la robustez y eficacia del modelo en entornos dinámicos.

En resumen, este proceso de optimización representa un paso estratégico para elevar la calidad y la utilidad de las predicciones, destacando la importancia de un enfoque integrado que aproveche tanto la riqueza de la información previa como la potencia del algoritmo genético. La fusión de estos elementos impulsa la capacidad del proyecto para proporcionar pronósticos más precisos y adaptativos, fundamentales para la toma de decisiones informadas en contextos temporales cambiantes.

Para lograr la integración efectiva de ambos algoritmos, se inicia con la creación de una estructura que facilite la generación y combinación de padres, fundamental para el funcionamiento del algoritmo genético. Esta estructura debe ser lo suficientemente básica para permitir cambios necesarios y, al mismo tiempo, proporcionar la flexibilidad requerida por el algoritmo genético. Con este fin, se ha concebido una lista que servirá como la "cadena genética" del padre.

En esta lista, cada hiperparámetro es asignado a una posición específica, generando así una representación ordenada y sistemática de los elementos que configuran al modelo. Para simplificar la manipulación de esta estructura, la "cadena genética" se compone exclusivamente de números. Cada número en esta cadena hace referencia a la posición de una opción específica dentro de la lista asociada al respectivo hiperparámetro.

Es importante destacar que, para optimizar la eficiencia y flexibilidad del proceso, la "cadena genética" se basa en números que representan las opciones disponibles para cada hiperparámetro. En otras palabras, cada hiperparámetro cuenta con una lista de posibles opciones, y los números en la "cadena genética" indican la posición de la opción correspondiente en dicha lista.

Con la estructura de los hiperparámetros de la serie de tiempo ajustada para ser compatible con la estructura de los genes en los algoritmos genéticos, estamos ahora listos para ejecutar el algoritmo genético. Sin embargo, es fundamental asignar los hiperparámetros específicos del algoritmo genético, que incluyen la tasa de mutación, la tasa de cruce, el método de selección de padres y el tamaño de la población [35].

Es crucial delimitar cuidadosamente los espacios de búsqueda de los diversos modelos lineales, ya que un espacio de búsqueda demasiado amplio podría afectar la eficiencia del algoritmo genético al enfrentarlo a un número excesivo de posibles soluciones. En este sentido, se han definido espacios de búsqueda específicos para los parámetros, con el objetivo de optimizar la búsqueda de soluciones viables. Los intervalos para cada parámetro se han establecido considerando la naturaleza del problema y la relación de los parámetros con el rendimiento del modelo.

Es fundamental destacar que la definición precisa de estos espacios de búsqueda contribuirá significativamente a la efectividad del algoritmo genético al reducir la complejidad del proceso de optimización. De esta manera, se espera que el algoritmo pueda explorar de manera más eficiente el conjunto de soluciones posibles, facilitando la identificación de configuraciones óptimas para los modelos lineales [36].

La cuidadosa selección de los intervalos de búsqueda también juega un papel crucial en la convergencia del algoritmo genético, ya que limita el espacio de soluciones factibles y permite un enfoque más enfocado en la optimización de los hiperparámetros. Esta estrategia busca encontrar un equilibrio entre la exhaustividad de la búsqueda y la eficiencia computacional, asegurando así resultados más efectivos en la tarea de ajustar los modelos lineales a las necesidades específicas del pronóstico de la demanda en el contexto de Fast Delivery. Con esto en mente se determinó el siguiente espacio de búsqueda para los modelos de series lineales:

Model	Parameter	Search Space
DNN	epochs	['10', '20', '30', '40', '50', '60', '70', '80', '90', '100']
	batch_size	['16', '32', '64', '128', '256', '312', '384', '448', '512', '576']
	hidden_layer_size	['50', '100', '150', '200', '250', '300', '350', '400', '450', '500']
	embedding_layer_size	['50', '100', '150', '200', '250', '300', '350', '400', '450', '500']
	weight_initialization	['he normal', 'glorot normal', 'normal']
	clipvalue	['0.1', '0.2', '0.3', '0.4', '0.5', '0.6', '0.7', '0.8', '0.9', '1.0']
	learning_rate	['0.001', '0.002', '0.003', '0.004', '0.005', '0.006', '0.007', '0.008', '0.009', '0.01']
	neuron_activation	['relu', 'tanh', 'sigmoid']
RNN	num_epochs	['5', '10', '15', '20', '25', '30', '35', '40', '45', '50']
	batch_size	['16', '32', '48', '64', '80', '96', '112', '128', '144', '160']

	recurrent_layer_size	['50', '100', '150', '200', '250', '300', '350', '400', '450', '500']
	weight_initialization	['he_normal', 'glorot_normal', 'normal']
	neuron_activation	['relu', 'tanh', 'sigmoid']
	clipvalue	['1', '2', '3', '4', '5', '6', '7', '8', '9', '10']
	input_standardization	['True', 'False']
	learning_rate	['0.0001', '0.0002', '0.0003', '0.0004', '0.0005', '0.0006', '0.0007', '0.0008', '0.0009', '0.001']
LSTM	num_epochs	['5', '10', '15', '20', '25', '30', '35', '40', '45', '50']
	batch_size	['16', '32', '48', '64', '80', '96', '112', '128', '144', '160']
	lstm_layer_size	['50', '100', '150', '200', '250', '300', '350', '400', '450', '500']
	weight_initialization	['he_normal', 'glorot_normal', 'normal']
	neuron_activation	['relu', 'tanh', 'sigmoid']
	clipvalue	['1', '2', '3', '4', '5', '6', '7', '8', '9', '10']
	input_standardization	['True', 'False']
	learning_rate	['0.0001', '0.0002', '0.0003', '0.0004', '0.0005', '0.0006', '0.0007', '0.0008', '0.0009', '0.001']

Tabla 2. Espacio de búsqueda para los modelos de series lineales.

La tasa de mutación determina la probabilidad de que un gen experimente una mutación durante la reproducción [37]. Por otro lado, la tasa de cruce indica la probabilidad de que dos individuos se crucen para dar lugar a nuevos descendientes. La selección de padres desempeña un papel fundamental en los algoritmos genéticos, y el tamaño de la población ha sido seleccionado cuidadosamente para equilibrar la exploración del espacio de soluciones con la eficiencia computacional.

Para este proyecto, se ha elegido un método específico explicado a profundidad en el libro “Evolutionary Optimization Algorithms” [31], considerando su eficacia demostrada en contextos similares. Así que, teniendo en cuenta todo lo anterior, se han asignado los siguientes hiperparámetros:

Parameter	Value
Population Size	50
Number of Generations	100
Time Stop [s]	100
Mutation Rate	100
Crossover Rate	100

Tabla 3. Hiperparámetros algoritmo genético

5.5 Evaluación y Comparación de Modelos

Según la literatura encontrada existen dos grandes metodologías para evaluar la efectividad en la predicción de un modelo y es con estas que se sugiere realizar la evaluación de los modelos propuestos en el numeral anterior [38].

MSE

El error cuadrático medio (Mean Squared Error) mide qué tan alejados está el modelo al conjunto de datos, esta es una función de riesgo correspondiente al valor esperado de la pérdida por error al cuadrado, tal y como se observa en la ilustración 6.




Ilustración 5. Metodología MSE

Entre mayor es el MSE significa que los puntos de la predicción están muy dispersos con respecto a los datos reales, mientras que un MSE más pequeño sugiere lo contrario. Por razones del problema específico de esta tesis se prefiere un MSE pequeño porque indica que el modelo logra predecir de mejor forma el forecast real. Lo anterior refleja la distribución centralizada de los datos, el hecho de que no está sesgado genera menos errores (errores causados por la dispersión de los puntos de datos) [39].

$$MSE = \frac{\sum_{i=1}^N (ForecastingValue - ActualValue)^2}{N}$$

Ecuación 1. Ecuación MSE

Para comparar de mejor forma se creó un Python una función donde se logra ranquear de mejor a peor MSE los diferentes modelos. Esta función se creó usando la ecuación 1 como base y se usó como ejemplo dos vectores lineales, uno usando la media de los datos de prueba y otra usando la media de los datos de entrenamiento.

Probando esta función se observa que el valor medio de entrenamiento, tiene un error cuadrático medio superior al test, ya que esta última tiene como base la media de los datos de prueba. Esto hace sentido con lo que se deduce que está bien implementada la herramienta para la evaluación de los modelos.

Labes	error_metric	rank
Average_value_on test	854,4818	1
Average_value_on train	1016,24	2

Tabla 4. Resultados de prueba utilizando el algoritmo de clasificación

R-square

El coeficiente de determinación R^2 es una métrica estadística fundamental que cuantifica la proporción de la variabilidad en la variable dependiente que puede ser explicada por las variables independientes. En el contexto de los algoritmos de optimización, especialmente

en el ámbito del aprendizaje automático y la regresión, R^2 desempeña un papel crucial como métrica de evaluación para medir la calidad del ajuste del modelo [40]. El coeficiente de determinación se calcula mediante la ecuación 2.

$$R^2 = 1 - \frac{TotalSumOfSquares}{SumOfSqueredResiduals}$$

Ecuación 2. Ecuación R-square

En esta fórmula, la Suma de Residuos Cuadrados (SSR) representa la suma de las diferencias al cuadrado entre los valores observados y los valores predichos por el modelo. Por otro lado, la Suma de Cuadrados Total (SST) representa la suma de las diferencias al cuadrado entre los valores observados y la media de los valores observados. Cuando R^2 es igual a cero, indica que el modelo no explica nada de la variabilidad en la variable de respuesta. Por el contrario, cuando R^2 es igual a 1, el modelo explica toda la variabilidad en la variable respuesta. En otras palabras, R^2 proporciona una medida de cuánto los variables independientes explican la variabilidad de la variable dependiente en el modelo. Por lo tanto, un R^2 más cercano a 1 indica un mejor ajuste del modelo a los datos como se observa en la ilustración 7 [41].




Ilustración 6. Ejemplo R-square.

En el proceso de entrenamiento del modelo, se seleccionan hiperparámetros específicos utilizando un algoritmo de optimización. La evaluación de la precisión del modelo se lleva a cabo utilizando métricas como R^2 , que se integra como una función objetivo en el algoritmo de optimización. Esta función guía el proceso de optimización al maximizar o minimizar el resultado, dependiendo de los objetivos específicos.

La utilidad de R^2 se extiende a la calibración de hiperparámetros, donde sirve como criterio para evaluar diversos modelos generados con diferentes configuraciones de hiperparámetros. En algoritmos genéticos u otras técnicas de optimización evolutiva, R^2 se incorpora como función de aptitud, asignando mayor aptitud a los individuos con valores más altos de R^2 .

La capacidad de monitorear R^2 también juega un papel importante en la determinación de la convergencia del proceso de optimización. Al alcanzar un nivel satisfactorio, se considera

que el proceso ha tenido éxito. Además, R^2 se utiliza para evaluar la convergencia de las soluciones en algoritmos genéticos, proporcionando información valiosa sobre la evolución de las soluciones a lo largo de las iteraciones [42].

Es esencial reconocer que la eficacia de R^2 depende de la naturaleza específica del problema y de los objetivos de optimización. Aunque R^2 es una métrica valiosa, tiene limitaciones, como su sensibilidad a valores atípicos y su incapacidad para proporcionar información detallada sobre la calidad de las predicciones para nuevos datos. En consecuencia, para una evaluación más completa de los modelos lineales, se recomienda complementar R^2 con métricas adicionales como el Error Cuadrático Medio (MSE) [43].

VI. Desarrollo y Resultados

6.1. Recursos computacionales

Se cuenta con una máquina virtual con sistema operativo Windows10, de 32GB de RAM y una memoria de 1TB

6.2. Análisis Exploratorio de Datos

Exploración de la serie de tiempo.

Para iniciar el análisis, se procedió a observar el comportamiento de la serie de tiempo mediante la creación de un gráfico de líneas simple. Esta representación gráfica inicial fue fundamental para obtener una visión general de la serie, permitiendo identificar posibles tendencias que podrían influir en el análisis posterior. La visualización inicial proporcionó una perspectiva preliminar que sirvió como punto de partida para comprender la dinámica subyacente de la serie de tiempo y orientó la aplicación de enfoques más detallados en etapas posteriores del análisis.




Ilustración 7. Serie de tiempo estudiada




Ilustración 8. Línea de tendencia de la serie de tiempo.

La ilustración 8 presenta una representación gráfica de la serie de tiempo, revelando un comportamiento lineal con una leve tendencia positiva. Sin embargo, dado que este gráfico proporciona una visión general de la serie, se optó por realizar una descomposición aditiva de la serie para obtener una comprensión más detallada. Este enfoque permitirá analizar con mayor precisión la tendencia, descomponiendo la serie en sus componentes fundamentales. Además, la descomposición facilitará la identificación del patrón de temporalidad presente en los datos y permitirá examinar la aleatoriedad inherente a la serie, contribuyendo así a una comprensión más completa y detallada de su estructura subyacente.



Ilustración 9. Descomposición de la serie de tiempo.

La ilustración 9 ofrece una visión detallada del comportamiento de la serie de tiempo. Inicialmente, se destaca una fase de declive seguida de una estabilización y, posteriormente, un aumento en el número de órdenes. Se identifica un patrón recurrente asociado con la hora del día, extendiéndose a lo largo de toda la serie temporal. Además, la presencia de aleatoriedad en los datos sugiere que factores externos, como caídas en el sistema de pedidos, promociones o eventos especiales, tienen un impacto positivo en la serie en la mayoría de las ocasiones. Esta observación resalta la influencia multifacética de diversos factores en la dinámica de la serie de tiempo.

En la fase siguiente, se llevó a cabo un análisis de correlación de los datos para identificar las relaciones existentes y determinar si estas se replican a lo largo de la serie temporal. La ilustración 10 muestra claramente que los datos presentan correlaciones más fuertes con sus valores inmediatamente cercanos, seguidas de correlaciones negativas con los patrones de 12 horas anteriores, y finalmente, exhiben correlaciones positivas con los datos de 24 horas previas. Este análisis detallado de correlación proporciona conclusiones adicionales sobre la estructura temporal de los datos y resalta la persistencia de ciertos patrones a lo largo del tiempo en la serie.




Ilustración 10. Gráfica de autocorrelación

Finalmente, se llevó a cabo un análisis detallado de los outliers en los datos para comprender la naturaleza de estos valores atípicos. Se aplicó la técnica del Rango Intercuartílico (IQR), que consiste en calcular la diferencia entre el tercer y el primer cuartil, identificando así las regiones donde los datos podrían considerarse atípicos. La ilustración 11 revela que, aunque existen outliers, no son lo suficientemente significativos como para justificar su eliminación de la serie temporal. Además, se observa que muchos de estos outliers están asociados con eventos de fechas especiales o interrupciones en el sistema que genera los órdenes, lo que sugiere que su presencia puede ser explicada por circunstancias particulares y no necesariamente indican errores en los datos. Este análisis

contribuye a una comprensión más completa de la serie temporal, permitiendo una evaluación informada de la presencia y la influencia de outliers en el conjunto de datos.




Ilustración 11. Serie de tiempo con los outliers resaltados.

Exploración de los modelos predictivos de series de tiempo.

Para esta parte se generaron varios modelos generales para analizar su comportamiento a un nivel de detalle específico. Para llevar a cabo esta evaluación, se sometieron estos modelos a pruebas realizadas a nivel diario. Esta estrategia de análisis detallado se diseñó para explorar la viabilidad de estos modelos en relación con los objetivos establecidos en esta tesis.

La elección de realizar pruebas diarias permitió una evaluación del desempeño de cada modelo, proporcionando información valiosa sobre su capacidad para predecir el número de pedidos en el contexto de una empresa de Fast Delivery. Este enfoque detallado no solo busca verificar la idoneidad de los modelos sino también proporcionar información útil para la iteración y mejora continua de estos en fases posteriores del proyecto. En las ilustraciones 12, 13, 14, 15 y 16 se presentan los resultados obtenidos de estas pruebas, ofreciendo una visión más profunda de cómo cada modelo se desempeñó frente a la tarea específica que se propuso abordar en este proyecto de grado.




Ilustración 12. Grafica de resultados Exponential Smoothing




Ilustración 13. Grafica de resultados Modelo ARIMA




Ilustración 14. Grafica de resultados modelo DNN




Ilustración 15. Grafica de resultados modelo RNN




Ilustración 16. Grafica de resultados modelo LSTM y RNN

Al examinar bien los resultados obtenidos, se evidencia que todos los modelos exhiben la capacidad de seguir el patrón presente en los datos de prueba, aunque algunos lo hacen con precisión superior. En este contexto, es interesante notar que el modelo exponencial se presenta como la excepción, ya que no logra adaptarse de manera efectiva a la secuencialidad presente en la información real. Este inconveniente podría derivarse de la limitación del modelo exponencial para manejar funciones logarítmicas, polinomiales o lineales, características que están presentes en el conjunto de datos evaluado [44].

La naturaleza restrictiva del modelo exponencial se manifiesta especialmente en la captura de relaciones entre datos que son complejas. Dada su estructura matemática, este tipo de modelo puede resultar menos adecuado para abordar la variabilidad y las sutilezas presentes en conjuntos de datos que exhiben patrones más elaborados. En contraste, las redes neuronales emergen como una alternativa más efectiva en estos escenarios, ya que su capacidad para aprender y adaptarse a patrones complejos las posiciona como herramientas más versátiles y robustas [45].

Es esencial reconocer que la elección de un modelo depende en gran medida de la naturaleza específica de los datos y los patrones que se pretenden capturar. En este caso, la limitación del modelo exponencial subraya la importancia de considerar la complejidad inherente de los datos y la necesidad de seleccionar modelos que se alineen más adecuadamente con dicha complejidad. Este análisis de los resultados sienta las bases para la toma de decisiones informadas en las fases posteriores del proyecto, orientadas hacia la mejora continua y la optimización de los modelos seleccionados.

6.3. Resultados de Algoritmos Tradicionales

La modificación del intervalo en la serie de tiempo se revela como una adaptación esencial en la resolución de este problema específico, donde la predicción precisa demanda una granularidad de 30 minutos. Este cambio estratégico responde directamente a la necesidad de ajustar el análisis temporal de manera más detallada, proporcionando una visión más precisa de la dinámica de la demanda en una empresa de Fast Delivery.

Considerando este ajuste, se procede a la evaluación de seis modelos distintos, cada uno diseñado para abordar las complejidades y particularidades de la serie de tiempo con intervalos de 30 minutos. El propósito fundamental de esta evaluación es discernir cuál de estos modelos exhibe la mayor precisión en la predicción del número de pedidos. Este enfoque comparativo se erige como un paso crucial en la identificación del modelo más

idóneo para enfrentar los desafíos específicos planteados por la naturaleza del negocio de Fast Delivery.

A continuación, se presentarán los resultados detallados de esta evaluación, destacando tanto las fortalezas como las limitaciones de cada modelo. Esta información será instrumental en la toma de decisiones posteriores, permitiendo elegir el modelo más preciso y formular estrategias de refinamiento y ajuste continuo para optimizar el rendimiento según las necesidades específicas de la predicción de la demanda en intervalos de 30.




Ilustración 17. Resultado de todos los algoritmos tradicionales

Model	error_m etric	ra nk
DNN ('EPOCHS': 25, 'EMBEDDING_LAYER_SIZE':64)	110,047	1
DNN ('EPOCHS': 25, 'EMBEDDING_LAYER_SIZE':32)	117,851	2
VAR ('covars':['num_stores'])	214,576	3
ARIMA ('resample_frequency':'W')	256,768	4
RNN ('activation': 'tanh','optimizer': 'adam','clipvalue':5,'learning_rate': 0.01,'epoch':5,'lstm_units':128)	258,768	5
LSTM ('activation': 'tanh','optimizer': 'adam','clipvalue':5,'learning_rate': 0.01,'epoch':5,'rnn_units':128)	275,601	6

Tabla 5. Resultados del MSE de los algoritmos tradicionales comparándolos con los datos reales

A partir de los análisis previos y la ilustración 17, se podría afirmar que el algoritmo de Redes Neuronales Profundas (DNN) es el que presenta el menor Error Cuadrático Medio (MSE), indicando un rendimiento superior en términos de precisión. Sin embargo, es fundamental reconocer que este resultado se logra bajo la suposición de ciertos hiperparámetros específicos en las otras redes neuronales. Además, es esencial destacar que estos hiperparámetros no necesariamente son los más apropiados para este conjunto de datos, y la elección de valores específicos puede depender en gran medida de las características y complejidades únicas de la serie temporal analizada.

Ante la diversidad de hiperparámetros que caracterizan a los modelos de redes neuronales, se introduce un enfoque estratégico: el diseño de un algoritmo de optimización. Este algoritmo tiene como propósito identificar y establecer la mejor combinación de hiperparámetros para cada modelo de redes neuronales, considerando la variabilidad inherente en los datos y ajustando los modelos de manera más precisa a las condiciones específicas del problema. En otras palabras, se busca superar la limitación de asumir hiperparámetros fijos y encontrar configuraciones óptimas que maximicen la capacidad

predictiva de cada red neuronal en el contexto de la predicción de la demanda en intervalos de 30 minutos.

Este enfoque de optimización no solo refuerza la robustez de los modelos de redes neuronales, sino que también contribuye a la generalización y aplicabilidad de los resultados obtenidos. Al personalizar los hiperparámetros de manera más precisa, se espera lograr un mejor ajuste a la complejidad inherente de la serie temporal, permitiendo así maximizar la eficacia de los modelos en la tarea crítica de anticipar la demanda en el ámbito de Fast Delivery. Este proceso de optimización se posiciona como un paso estratégico para mejorar aún más la calidad y confiabilidad de las predicciones en el marco de este proyecto de grado.

6.4. Resultados de Redes Neuronales

Grid Search VS Algoritmo Genético

El Grid Search, como algoritmo de optimización, adopta un enfoque exhaustivo al explorar cada posible solución en el espacio de búsqueda. En contraste, el algoritmo genético elige posibles respuestas para generar un recorrido más extenso sin necesariamente pasar por cada respuesta individual. Ante la pregunta evidente de por qué optar por un algoritmo genético, limitado en el número de soluciones, cuando se puede recorrer cada respuesta con el Grid Search, la respuesta radica en la naturaleza del espacio de solución.

Los algoritmos genéticos demuestran su eficacia cuando se enfrentan a espacios de solución complejos y de alta dimensión. En estos entornos, los algoritmos genéticos pueden explorar más posibilidades de manera más eficiente en comparación con un Grid Search, que puede volverse poco práctico o computacionalmente costoso en funciones grandes y complejas [46].

Para evaluar la idoneidad de elegir entre el Grid Search y el algoritmo genético, se diseñó un experimento que puso a competir a ambos. Este experimento se propuso medir cuántas posibles soluciones exploró cada algoritmo, qué nivel de ajuste (fit) lograron y cuánto convergieron los resultados durante un periodo de tiempo específico.

En el marco de este experimento, se enfocó en el modelo lineal DNN (Red Neuronal Profunda). Los resultados obtenidos en este ejercicio proporcionarán información valiosa sobre el desempeño relativo de cada algoritmo en términos de eficiencia, capacidad de ajuste y convergencia. Estos resultados no solo guiarán la elección del algoritmo más adecuado para las necesidades específicas del problema, sino que también informarán sobre la eficacia general de cada enfoque en un contexto de optimización más amplio.

DNN	Grind Search	Genetic Algorithm
Fitness of the best Solution	0,8426	0,8634
25th Percentile of Fitness (Las Gen)	-28,8686	0,863473
50th Percentile of Fitness (Las Gen)	-6,9338	0,863473
75th Percentile of Fitness (Las Gen)	-1,8014	0,863473
Total Time Elapsed (Seconds)	3657,33	3182,33
Number of Models trained	900	334
Coverage over Search Space (%)	0,05	0,01855

Number of Generation Run	30	100
Interrupted due to Time Constrains	True	False

Tabla 6. Resultados experimento con modelo DNN usando Grind Search y Algoritmo Genético

De la conclusión obtenida en el experimento anterior, se destaca que el algoritmo genético, a pesar de recorrer un menor número de soluciones, exhibió un ajuste significativamente mejor en comparación con el algoritmo Grid Search. No solo se logró un rendimiento superior, sino que también se observó una notable tendencia a que las soluciones evaluadas por el algoritmo genético fueran cada vez más cercanas entre sí. En contraste, con el Grid Search, los resultados presentaron una dispersión más pronunciada, lo que sugiere una mayor variabilidad en la calidad de las soluciones exploradas.

Un aspecto interesante es el tiempo que llevó al algoritmo genético a alcanzar resultados óptimos. Se observó que este enfoque logró resolver el problema en un período de tiempo menor en comparación con el Grid Search. Esta eficiencia temporal representa una ventaja significativa, especialmente en entornos donde la toma de decisiones debe realizarse en lapsos cortos, como es común en la gestión de empresas de Fast Delivery.

Para validar aún más la preferencia por el algoritmo genético y descartar definitivamente el Grid Search, se llevó a cabo un experimento similar utilizando otra serie de tiempo. En esta ocasión, se empleó un modelo de Redes Neuronales Recurrentes (RNN). A continuación, se presentan los resultados de este experimento, que proporcionarán una visión más completa sobre la eficacia y la generalización de cada algoritmo en diferentes contextos de series temporales. Estos resultados serán fundamentales para consolidar las conclusiones y orientar la elección del algoritmo más apropiado para abordar la complejidad de la predicción de la demanda en Fast Delivery.

RNN	Grind Search	Genetic Algorithm
Fitness of the best Solution	0,86221	0,864
25th Percentile of Fitness (Las Gen)	-1,549	0,6959
50th Percentile of Fitness (Las Gen)	-0,0989	0,8367
75th Percentile of Fitness (Las Gen)	0,6693	0,8525
Total Time Elapsed (Seconds)	4550	3917,26
Number of Models trained	120	102
Coverage over Search Space (%)	0,06	0,056
Number of Generation Run	4	5
Interrupted due to Time Constrains	True	True

Tabla 7. Resultados experimento con modelo RNN usando Grind Search Algoritmo Genético

Los resultados obtenidos mediante el uso del Grid Search para este algoritmo presentan similitudes notables con los resultados obtenidos mediante el Algoritmo Genético. Sin embargo, como se evidenció previamente en el experimento con el modelo DNN, el Algoritmo Genético exhibe una característica distintiva al mostrar una dispersión significativamente menor en las soluciones evaluadas. Este patrón refleja una mayor consistencia en la calidad de las soluciones obtenidas a lo largo de las iteraciones, lo que garantiza la fiabilidad y estabilidad de los resultados.

En consonancia con los hallazgos previos, el Algoritmo Genético demuestra su capacidad para explorar menos posibles soluciones sin sacrificar la calidad del resultado final. Este aspecto es de especial relevancia, ya que sugiere que el enfoque genético logra una

optimización más eficiente y precisa al converger rápidamente hacia soluciones de alto rendimiento.

Asimismo, otro aspecto destacado es la eficiencia temporal del Algoritmo Genético en comparación con el Grid Search. La duración significativamente menor del proceso de optimización con el Algoritmo Genético implica un ahorro sustancial de recursos computacionales, lo cual es crucial en situaciones donde el tiempo de respuesta es un factor crítico.

Basándonos en estos resultados consistentes y favorables, se toma la decisión de utilizar el Algoritmo Genético como el algoritmo de optimización para la siguiente etapa de este trabajo de grado. Esta elección se fundamenta en la capacidad demostrada del Algoritmo Genético para abordar de manera efectiva la complejidad del espacio de solución, proporcionando resultados de alta calidad de manera eficiente y confiable.

Solución a valores indeterminados

Debido a la posibilidad de que el algoritmo genético conduzca a soluciones con valores indeterminados, se ha identificado la necesidad de incorporar una función adicional que penalice estos valores en la función de fitness. En respuesta a este desafío, se han diseñado dos enfoques para abordar el problema:

- *Algoritmo A: Incorporación del Coeficiente de Determinación (R-cuadrado):* Este algoritmo ajusta el coeficiente de determinación (R-cuadrado) del modelo en la función de fitness. En casos donde el R-cuadrado es indeterminado o negativo, se ajusta a cero y se añade una pequeña constante positiva. El objetivo es rescatar todos los modelos, proporcionándoles una probabilidad de selección positiva proporcional al valor del R-cuadrado. En otras palabras, el Optimizador A busca preservar todos los modelos, otorgándoles una probabilidad de selección positiva a toda costa.
- *Algoritmo B: Ajuste y Penalización Exponencial:* Este algoritmo, en primer lugar, ajusta los valores de R-cuadrado indeterminados o negativos a cero, sin adición de constantes. Luego, aplica una función exponencial a los valores de R-cuadrado positivos. Los modelos con R-cuadrado negativo o indeterminado son eliminados con una penalización severa, mientras que los modelos con R-cuadrado positivo ven aumentada exponencialmente su probabilidad de selección. Esta intensificación de la penalización a medida que se aproximan a cero destaca la importancia de valores más altos de R-cuadrado en la selección del modelo.

Para determinar cuál de las dos opciones es más efectiva, se llevó a cabo un experimento utilizando un modelo DNN con pocos hiperparámetros. El objetivo es evaluar cómo se comportan las generaciones a lo largo del tiempo y qué tan buenos resultados arrojan cada una de las soluciones propuestas. Los resultados obtenidos se presentarán a continuación, proporcionando una visión detallada sobre la eficacia y la idoneidad de cada enfoque en el contexto específico del problema abordado.



Ilustración 18. Resultados del experimento entre los algoritmos A y B.

Los resultados del experimento (ilustración 18) proporcionan una valiosa perspectiva sobre la eficacia de las dos opciones propuestas para abordar la penalización de valores indeterminados o negativos de R-cuadrado en el algoritmo genético. Se concluye que la estrategia de penalización exponencial, combinada con la eliminación directa de modelos indeterminados en el Optimizador B, genera una selección más rápida de modelos eficaces, acelerando significativamente la convergencia, especialmente en las fases iniciales del algoritmo genético.

Un aspecto destacado observado en la gráfica es la rápida ascensión del percentil 75 de la función de fitness del Optimizador B (sin ajuste), en comparación con el Optimizador A, durante las primeras cinco generaciones en promedio. Este comportamiento indica que la penalización exponencial, al intensificar la penalización a medida que los valores de R-cuadrado se aproximan a cero, impulsa una selección más eficiente de modelos prometedores desde el principio del proceso evolutivo.

En consecuencia, la elección del algoritmo B como el penalizador en las generaciones subsiguientes del algoritmo genético se justifica por su capacidad para acelerar la convergencia y favorecer la identificación temprana de modelos con un desempeño significativamente mejor. Este enfoque se alinea con el objetivo de optimizar la eficiencia del algoritmo genético, maximizando la probabilidad de seleccionar modelos de alta calidad y mejorando la rapidez del proceso de búsqueda en el espacio de soluciones.

6.5. Comparación y Análisis de Resultados

Para evaluar previamente los resultados finales, se genera una gráfica que permita visualizar comparativamente el pronóstico generado por la mejor configuración de cada modelo en contraste con los valores reales observados. La representación gráfica de estos resultados brinda una perspectiva clara y concisa de la capacidad predictiva de cada modelo frente a la realidad de la demanda.

La siguiente sección presenta dicha gráfica, la cual se compone de las curvas que representan las predicciones óptimas obtenidas por cada modelo en función del tiempo, junto con la serie temporal real de la variable de interés. Esta representación gráfica se convierte en una herramienta visual clave para la evaluación cualitativa de la precisión de los modelos, permitiendo identificar patrones, tendencias y posibles desviaciones entre las predicciones y los datos reales.

Es importante destacar que esta visualización inicial sirve como punto de partida para comprender la calidad de las predicciones de cada modelo, aunque se complementará con análisis más detallados y métricas cuantitativas en etapas posteriores del proceso de evaluación y ajuste de los modelos. La interpretación de la gráfica proporcionará insights valiosos sobre la capacidad de los modelos para capturar la dinámica de la serie temporal y orientará las acciones a seguir en la refinación de los hiperparámetros y la mejora continua del rendimiento predictivo.




Ilustración 19. Grafica de resultados con algoritmo genético modelo DNN




Ilustración 20. Grafica de resultados con algoritmo genético modelo RNN




Ilustración 21. Grafica de resultados con algoritmo genético LSTM

De las ilustraciones 19, 20 y 21, se observa de manera inmediata el desempeño de los modelos lineales estudiados. Al examinarlos superficialmente, se aprecia que tanto el modelo DNN como el RNN exhiben un rendimiento similar, destacándose por su habilidad para imitar de manera más precisa el comportamiento de los datos reales. Sin embargo, se nota que el DNN tiende a ser un poco más cauteloso en momentos de demanda máxima.

Al profundizar en la evaluación del algoritmo LSTM, se percibe que, aunque logra identificar periodos de menor demanda y emula en cierta medida el patrón de los datos reales, presenta dificultades para prever con precisión los picos de ventas. Este comportamiento revela aspectos específicos de la capacidad predictiva de cada modelo, proporcionando una visión inicial de sus fortalezas y limitaciones en relación con la serie temporal estudiada.




Ilustración 22. Grafica de evolución del con algoritmo genético para en DNN




Ilustración 23. Grafica de evolución del con algoritmo genético para en RNN




Ilustración 24. Grafica de evolución del con algoritmo genético para en RNN acercada




Ilustración 25. Grafica de evolución del con algoritmo genético para en LSTM

A través del análisis de los gráficos representados en las ilustraciones 22, 23, 24 y 25 que representan la evolución de los resultados finales, se destaca el sólido desempeño inicial del modelo DNN en su primera generación. Se evidencia una convergencia notablemente más rápida del percentil del 75%, en comparación con los otros dos modelos. Por otro lado, el modelo RNN presenta un inicio con valores de R^2 dispersos que, al examinar detenidamente, logran estabilizarse en las primeras 50 generaciones. Posteriormente, se observa una estabilización progresiva del percentil del 75% después de la generación 100.

En contraste, el modelo LSTM muestra una dinámica peculiar, ya que su cantidad de generaciones no supera las 2. Esto indica un costo computacional significativamente mayor en comparación con el RNN, que logró ejecutar 246 generaciones en un periodo ligeramente inferior al 75% del tiempo empleado por el LSTM. Este dato resalta la diferencia en eficiencia entre los algoritmos, subrayando la importancia de considerar el rendimiento computacional al evaluar los modelos.

A continuación, se presentan los resultados óptimos obtenidos mediante el algoritmo genético para los tres modelos de series temporales:

Model	hyperparameters	results
DNN	epochs	90
	batch_size	312
	hidden_layer_size	150
	embedding_layer_size	500
	weight_initialization	he_normal
	clipvalue	0.9
	learning_rate	0.01
	neuron_activation	sigmoid
	Fitness	0,873489
	Elapsed Time	1h 18m 31s
	25th Percentile_Last_generation	0,863500
	50th Percentile_Last_generation	0,873490
	75th Percentile_Last_generation	0,873490
RNN	num_epochs	30
	batch_size	32
	recurrent_layer_size	50
	weight_initialization	glorot_normal
	neuron_activation	relu
	clipvalue	6
	input_standardization	False
	learning_rate	0.0006
	Fitness	0,876477
	Elapsed Time	37h 56m 3s
	25th Percentile_Last_generation	0,859190
	50th Percentile_Last_generation	0,870610
	75th Percentile_Last_generation	0,876480
LSTM	num_epochs	50
	batch_size	16
	lstm_layer_size	400

weight_initialization	glorot_normal
neuron_activation	tanh
clipvalue	3
input_standardization	True
learning_rate	0.001
Fitness	0,774737
Elapsed Time	51h 22m 48s
25th Percentile Last generation	-0,667820
50th Percentile Last generation	-0,252160
75th Percentile Last generation	0,167070

Tabla 8. Resultados de las tres series de tiempo optimizadas.

Basándonos en estos resultados, podemos concluir que el modelo de algoritmo RNN exhibe la mayor precisión entre los tres modelos, ya que presenta el mejor valor de fitness. No obstante, es importante destacar que el algoritmo DNN no se queda atrás, ya que su respuesta tiene una desviación del 0,34% respecto al mejor resultado, lo que indica un desempeño bastante óptimo. En contraste, el algoritmo LSTM muestra el peor desempeño, ya que no solo exploró solo 2 generaciones durante todo el experimento, sino que también arrojó el peor valor de R^2 .

6.6. Implicaciones para la Programación de Personal

El análisis detallado revela la presencia de un modelo que demuestra ser lo suficientemente robusto como para generar predicciones confiables de los datos, destacándose por un R^2 que supera el 0.85. Este resultado es particularmente significativo considerando la naturaleza de la demanda en el contexto de un sistema de Fast Delivery, donde la variabilidad puede ser considerable.

En este contexto, el modelo basado en Redes Neuronales Recurrentes (RNN) emerge como una opción destacada. Su capacidad para anticipar y pronosticar los picos de demanda, combinada con un R^2 aceptable, y unos recursos temporales óptimos, sugiere que podría ser la elección óptima para este tipo de negocio. La precisión en la predicción de los momentos críticos es fundamental para una operación eficiente en el sector de entregas rápidas.

La aplicación de este modelo ofrece la posibilidad de lograr un número de personal más estable en los próximos meses, permitiendo una planificación más precisa del personal y optimizando los recursos de manera efectiva. Además, contribuirá a la gestión de una flota de domiciliarios adecuada para hacer frente a la creciente demanda, resultando en ahorros operativos y, al mismo tiempo, asegurando el cumplimiento de la promesa de valor característica de los servicios de entrega rápida.

VII. Conclusiones y Recomendaciones

7.1 Síntesis de Hallazgos Principales

Entre todos los modelos de series temporales examinados, las series de tiempo se destacan como los generadores de los mejores resultados. En un primer análisis, el algoritmo DNN demuestra ser el más efectivo al obtener el menor MSE, destacándose por su capacidad para ajustarse y predecir con precisión los patrones de los datos.

Es crucial resaltar que, en problemas de este tipo, el Grid Search muestra resultados inferiores en comparación con un algoritmo genético. El Grid Search exhibe mayor dispersión, menor precisión y un consumo computacional más elevado. Este hallazgo respalda la preferencia por algoritmos genéticos para la optimización en este contexto.

Cuando se enfrenta a resultados indeterminados en algoritmos genéticos, la metodología más efectiva es la aplicación de ajustes y penalización exponencial. Esta técnica reduce la dispersión, acelerando así la convergencia hacia el mejor resultado.

El algoritmo LSTM, a pesar de su potencial, muestra limitaciones al consumir recursos computacionales significativos al iterar a través del algoritmo genético. Este enfoque resulta en una exploración de soluciones limitada y predicciones poco precisas.

Por otro lado, los algoritmos RNN y DNN se posicionan como los más eficientes en la generación de predicciones de alta calidad, consumiendo recursos computacionales mínimos. Ambos son opciones sólidas para generar pronósticos de órdenes, destacando el RNN por su capacidad para prever con precisión los picos de demanda.

7.2 Implicaciones Practicas

La aplicación de este modelo no solo proporciona la oportunidad de mantener el manejo de personal estable en los próximos meses, permitiendo una planificación precisa del personal y una óptima utilización de los recursos, sino que también contribuirá significativamente a la gestión eficiente de una flota de domiciliarios para hacer frente al aumento de la demanda. Esto se traduce en ahorros operativos y garantiza el cumplimiento constante de la promesa de valor distintiva de los servicios de Fast Delivery.

Además, al contar con el mejor modelo para prever la demanda en un negocio de Fast Delivery, se establecen las bases para implementar estrategias que aseguren la cantidad necesaria de repartidores, cumpliendo así con la promesa de valor de la empresa. Este enfoque evolucionará en la programación de actividades en los centros de acopio, permitiendo una mayor sincronización en la recepción de mercancía, el conteo de inventario, la organización de racks y otras actividades, adaptado a la fluctuación de pedidos.

7.3 Limitaciones del Estudio

En este proyecto de grado, la información recopilada sobre las órdenes se encuentra limitada, ya que solo incluye el número de órdenes en un determinado periodo de tiempo. Esta limitación impide la segmentación del estudio y, como consecuencia, afecta la capacidad de generar un pronóstico más preciso y detallado.

Para mejorar la precisión del pronóstico y proporcionar una visión más completa de la dinámica de las órdenes en la empresa de Fast Delivery, sería beneficioso incorporar otras variables relevantes. Estas variables adicionales podrían incluir información demográfica de los clientes, patrones de consumo, eventos especiales que podrían afectar la demanda, condiciones climáticas y cualquier otro factor que pueda influir en la generación de órdenes.

Al incorporar estas variables adicionales al análisis, se abriría la puerta a una segmentación más detallada y a un mejor entendimiento de los factores que influyen en la demanda de órdenes. Esto, a su vez, permitiría desarrollar modelos más sofisticados y precisos para la

predicción de la demanda, lo cual es crucial para optimizar las operaciones de Fast Delivery y garantizar una entrega eficiente y satisfactoria para sus clientes.

7.4 Recomendaciones para Futuras Investigaciones

Dado que la información recopilada inicialmente carecía del nivel de detalle necesario y que este nivel podría tener un impacto significativo en los hiperparámetros del modelo, es esencial considerar la posibilidad de cambios sustanciales en dichos hiperparámetros a medida que se incorpore nueva información.

La metodología empleada para desarrollar el modelo en este proyecto de grado tiene la flexibilidad necesaria para adaptarse a la inclusión de datos más detallados. Al segmentar y analizar diversas variables que anteriormente no estaban disponibles, se abre la posibilidad de descubrir patrones más específicos y ajustar los hiperparámetros de manera más precisa.

La replicación de la metodología con la nueva información permite explorar y desarrollar diferentes modelos adaptados a cada variable específica. Esta segmentación más detallada puede revelar relaciones y comportamientos que anteriormente no fueron evidentes, brindando así la oportunidad de mejorar la capacidad predictiva y la eficacia del modelo general.

En resumen, la incorporación de información detallada no solo puede cambiar los hiperparámetros existentes, sino que también permite descubrir nuevas configuraciones y enfoques para optimizar la predicción de la demanda en el contexto de Fast Delivery. Este enfoque iterativo y adaptable contribuirá a la robustez y la capacidad de adaptación del modelo a medida que evoluciona con la disponibilidad de datos más completos.

VIII. Referencias

- [1] BBVA, «¿Qué es una 'startup'?,» 25 abril 2018. [En línea]. Available: <https://www.bbva.com/es/que-es-una-startup/>. [Último acceso: 29 noviembre 2022].
- [2] Hexacris, «Tour por el Hub principal de JOKR, conoce como opera el Delivery 2.0,» youtube, Santiago, 2022.
- [3] C. Polat, «The Role of Forecasting and Its Potential for Functional Management: A Review from the Value-Chain Perspective,» *Dokuz Eylül Üniversitesi*, vol. 9, nº 1, pp. 373-398, 2007.
- [4] C. K. Andreas Jessen, FORECASTING MANAGEMENT, Kalmar: Baltic Business School, 2009.
- [5] G. E. & S. L. C. Dieter, Engineering design, vol. 3, New York: McGraw-Hill., 2013.
- [6] Mukund, «simplilearn,» Project management, 10 Marzo 2017. [En línea]. Available: <https://www.simplilearn.com/wbs-approach-in-project-management-article>. [Último acceso: 25 Enero 2018].

- [7] R. Raj, «Silicon Canals,» 25 Marzo 2021. [En línea]. Available: <https://siliconcanals.com/news/startups/gorillas-raises-244m/>. [Último acceso: 30 noviembre 2022].
- [8] J. Caparoso, «Turbo acelera su expansión para ser el ala más rentable de Rappi,» *Forbes Colombia*, 17 mayo 2022.
- [9] C. L. Jain, *FUNDAMENTALS OF DEMAND PLANNING & FORECASTING*, Great Neck: Graceway Publishing Company, Inc, 2012.
- [10] S. S. M. W. Alexander Hess, «Real-time demand forecasting for an urban delivery platform,» *Transportation Research Part E: Logistics and Transportation Review*, vol. 145, 2021.
- [11] ITC INFOTECH, 20 Mayo 2022. [En línea]. Available: [https://www.itcinfotech.com/blogs/machine-learning-models-for-demand-forecasting/#:~:text=Demand%20forecasting%20is%20the%20process,%2DBoylan%20Approximation%20\(SBA\)..](https://www.itcinfotech.com/blogs/machine-learning-models-for-demand-forecasting/#:~:text=Demand%20forecasting%20is%20the%20process,%2DBoylan%20Approximation%20(SBA)..) [Último acceso: 30 Noviembre 2022].
- [12] W. P. a. S.-M. Ch, *Time Series Analysis, Modeling and Applications*, Springer, 2013.
- [13] A. B. K. J. K. O. R. D. S. Rob J. Hyndman, *Forecasting with Exponent Smoothing*, Springer, 2008.
- [14] H. V. T. R. o. B. I. S. (. Ravinder, «Forecasting With Exponential Smoothing – What's The Right Smoothing Constant?,» *Review of Business Information Systems*, vol. 17, nº 3, p. 117, 2013.
- [15] A. G. C. H. Meng-Chen Hsieh, «The propagation and identification of ARMA demand under simple exponential smoothing: forecasting expertise and information sharing,» *IMA Journal of Management Mathematics*, vol. 31, nº 3, p. 307–344, 2020.
- [16] A. C. Harvey, *Forecasting, Structural Time Series Models and the Kalman Filter*, Cambridge : Cambridge University Press, 1990.
- [17] S. Jiang, «ARIMA forecasting of China's coal consumption, price and investment by 2030,» *Energy Sources, Part B: Economics, Planning, and Policy*, vol. 13, p. 190.195, 2018.
- [18] S. G. R. José Américo Fernandes de Souza, «A forecasting model based on ARIMA and artificial neural networks for end-OF-life vehicles,» *Journal of Environmental Management*, vol. 318, 2022.
- [19] Y. Ning, «A comparative machine learning study for time series oil production forecasting: ARIMA, LSTM, and Prophet,» *Computers & Geosciences*, vol. 164, p. 11, 2022.

- [20] J. T. W. Patrick T. Brandt, Basic vector autoregression models., SAGE Publications, Inc., 2007.
- [21] X. Y. S. Z. X. L. M. J. P. Xiangang Luo, «A hybrid support vector regression framework for streamflow forecast,» *Journal of Hydrology*, vol. 568, pp. 184-193, 2019.
- [22] D. U. Wutsqa, «The VAR-NN-Model for Multivariate Time Series Forecasting,» *Mat Stat*, vol. 8, n° 1, pp. 35-43, 2008.
- [23] R. S. Hegde, «Novel Optical Systems, Methods, and Applications XXII Deep Neural Network (DNN) surrogate models for the accelerated design of optical devices and systems: Moving beyond fully-connected feedforward architectures,» de *Novel Optical Systems, Methods, and Applications XXII*, Gandhinagar, 2019.
- [24] M. Ekman, Learning Deep Learning, NVIDIA Corporation, 2022.
- [25] C. B. K. B. Hansika Hewamalage, «Recurrent Neural Networks for Time Series Forecasting: Current status and future directions,» *International Journal of Forecasting*, vol. 37, n° 1, pp. 388-427, 2021.
- [26] D. K. Radoslaw M. Cichy, «Deep Neural Networks as Scientific Models,» *Trends in Cognitive Sciences*, vol. 23, n° 4, pp. 305-315, 2019.
- [27] P. W. W. M. X. T. S. F. Jiandong Duan, «Short-term wind power forecasting using the hybrid model of improved variational mode decomposition and Correntropy Long Short-term memory neural network,» *Energy*, vol. 214, n° 1, 2021.
- [28] M. B. M. L. T. P. J. R. S. C. J. T. T. U. M. B. A.-L. B. D. D. M. L. Bernd Bischl, «Hyperparameter Optimization: Foundations, Algorithms, Best Practices and Open Challenges,» *WIREs Data Mining and Knowledge Discovery*, vol. 13, n° 2, 2023.
- [29] D. H. Bernd Bischl, «Multi-objective parameter configuration of machine learning algorithms using model-based optimization,» de *IEEE Symposium Series on Computational Intelligence (SSCI)*, Athens, Greece , 2016.
- [30] A. Deng, «Time Series Cross Validation: Theoretical Properties and Empirical Performance,» *Economics Letters*, vol. 223, 2023.
- [31] J. McCall, «Genetic algorithms for modelling and optimisation,» *Journal of Computational and Applied Mathematics*, vol. 184, n° 1, pp. 205-222, 2005.
- [32] D. J. Simon, Evolutionary Optimization Algorithms, Cleveland: WILEY, 2013.
- [33] W. P. Ruijun Dong, «A granular time series approach to long-term forecasting and trend forecasting,» *Physica A: Statistical Mechanics and its Applications*, vol. 387, n° 13, pp. 3253-3270, 2008.

- [34] R. B. a. F. A. Marina Hirota Magalhães, «Granular Models for Time-Series Forecasting,» de *Handbook of Granular Computing*, Alberta, John Wiley & Sons, 2008, pp. 949 - 967.
- [35] G. G. M. E. Ken Koshy Varghese, «Effect Of Spatio-Temporal Granularity On Demand Prediction For Deep Learning Model,» *Transport and Telecommunication*, vol. 24, nº 1, pp. 22-32, 2023.
- [36] L. M. P. Villanueva, «Análisis comparativo de optimización de hiperparámetros por búsqueda en grilla y algoritmos genéticos para forecasting de XGBoost en ventas online,» *CITAS*, vol. 9, nº 2, 2023.
- [37] D. M. Venkatesh S. S., «Variable Search Space Converging Genetic Algorithm for Solving System of Non-linear Equations,» *Journal of Intelligent Systems*, vol. 1, nº 30, pp. 142-164, 2020.
- [38] S. E. H. Randy L. Haupt, «Optimum Population Size and Mutation Rate for a Simple Real Algorithm that Optimizes Array Factors,» *ACES*, vol. 15, nº 2, pp. 94-102, 2000.
- [39] S. Zheng, «Methods of Evaluating Estimators,» Missouri State university, Springfield, 2020.
- [40] B. Vasumathi, «Enhancement of Intermittent Demands in Forecasting for Spare Parts Industry,» *Indian Journal of Science and Technology*, vol. 8, nº 25, p. 8, 2015.
- [41] J. A. E. C. R. Dalson Figueiredo, «What is R2 all about?,» *Leviathan*, vol. 3, nº 1, pp. 60-68, 2011.
- [42] D. H. L. M. S. C. Manisha Keer, «Goodness of Fit for Linear Regression using R squared and Adjusted RSquared,» *International Journal of Research Publication and Reviews*, vol. 4, nº 3, pp. 2431-2439, 2023.
- [43] M. M. N. A. M. Mahdi Roozbeha, «Penalized least squares optimization problem for high-dimensional data,» *International Journal of Nonlinear Analysis*, vol. 14, nº 1, pp. 245-250, 2023.
- [44] M. J. W. G. J. Davide Chicco, «The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation,» *PeerJ Comput Science*, vol. 7, nº 3, pp. 623-647, 2021.
- [45] M. S. U. Handanhal V. Ravinder, «Forecasting With Exponential Smoothing – What's The Right Smoothing Constant?,» *Review of Business Information Systems* –, vol. 17, nº 3, pp. 117-126, 2013.
- [46] E. S. G. Jr, «Exponential smoothing: The state of the art—Part II,» *International Journal of Forecasting*, vol. 22, nº 4, pp. 647-666, 2006.

- [47] M. D. H. Daniel Mesafint Belete, «Grid search in hyperparameter optimization of machine learning models for prediction of HIV/AIDS test results,» *International Journal of Computers and Applications*, vol. 44, nº 1, pp. 1-12, 2021.
- [48] A. Hayes, «Investopedia,» 01 Febrero 2022. [En línea]. Available: [https://www.investopedia.com/terms/s/sma.asp#:~:text=A%20simple%20moving%20average%20\(SMA\)%20is%20an%20arithmetic%20moving%20average,periods%20in%20the%20calculation%20average..](https://www.investopedia.com/terms/s/sma.asp#:~:text=A%20simple%20moving%20average%20(SMA)%20is%20an%20arithmetic%20moving%20average,periods%20in%20the%20calculation%20average..) [Último acceso: 30 Noviembre 2022].
- [49] S. Winds, «Orange Matter,» 15 Diciembre 2019. [En línea]. Available: [https://orangematter.solarwinds.com/2019/12/15/holt-winters-forecasting-simplified/#:~:text=What%20is%20the%20Holt%2DWinters,cyclical%20repeating%20pattern%20\(seasonality\)..](https://orangematter.solarwinds.com/2019/12/15/holt-winters-forecasting-simplified/#:~:text=What%20is%20the%20Holt%2DWinters,cyclical%20repeating%20pattern%20(seasonality)..) [Último acceso: 30 Noviembre 2022].
- [50] V. & F. K. Christou, «On count time series prediction,» *Journal of Statistical Computation and Simulation*, vol. 2, p. 85, 2015.
- [51] E. A. S. d. S. A. L. D. F. Edson Zangiacomi Martinez, «A SARIMA forecasting model to predict the number of cases of dengue,» *Revista da Sociedade Brasileira de Medicina Tropical*, vol. 44, nº 4, 2011.
- [52] W. A. R. Juan Gabriel Brida, «Tourism demand forecasting with SARIMA models – the case of South Tyrol,» *Tourism Economics*, vol. 17, nº 1, p. 209–221, 2011.
- [53] B. Artley, «Towards Data Science,» 26 Abril 2022. [En línea]. Available: <https://towardsdatascience.com/time-series-forecasting-with-arima-sarima-and-sarimax-ee61099e78f6>. [Último acceso: 01 Mayo 2023].
- [54] F. D. P. B. C. U. Taha Falatouria, «Predictive Analytics for Demand Forecasting - A comparison of SARIMA and LSTM in Retail SCM,» de *3rd International Conference on Industry 4.0 and Smart Manufacturing*, Wehrgabengasse, 2022.
- [55] S. S. M. W. Alexander Hess, «Real-time demand forecasting for an urban delivery platform,» *Transportation Research Part E: Logistics and Transportation Review*, vol. 145, nº 1, 2021.